

REDE NEURAL PARA A DIFERENCIAL DE CÃES E GATOS UTILIZANDO DEEP LEARNING

João Victor da Paz Nascimento, Juan Vila Nova Rojas Moreno, Matheus Luciano de Caldas Figueiredo, Davi Gleristone Alves Gomes, Luciano de Souza Cabral

Curso Médio integrado de Desenvolvimento de Sistemas – Instituto Federal de Educação,
Ciência e Tecnologia de Pernambuco (IFPE - Campus Jaboatão dos Guararapes)
Caixa Postal 54080-000 – Jaboatão dos Guararapes – PE – Brazil

jvpng1@discente.ifpe.edu.br,

jvnrm@discente.ifpe.edu.br,

mlcf@discente.ifpe.edu.br,

dgag@discente.ifpe.edu.br,

luciano.cabral@jaboatao.ifpe.edu.br

Abstract. *This work presents a binary classification model for dog and cat images using a convolutional neural network trained on the Cat_and_Dog.csv dataset, available on Kaggle. The images were processed in 128×128 pixel format, with a batch size of 32 and a sigmoid activation function for binary classification. The model achieved an accuracy of 90.54%, surpassing results presented in the reference article (89.74%). The tests demonstrate good generalization capacity, although specific errors are related to the imbalance of the dataset. The results reinforce the relevance of CNNs for computer vision tasks and indicate possible future improvements.*

Resumo. *Este trabalho apresenta um modelo de classificação binária para imagens de cães e gatos utilizando uma rede neural convolucional treinada sobre o dataset Cat_and_Dog.csv, disponível no Kaggle. As imagens foram processadas no formato 128×128 pixels, com batch size de 32 e função de ativação sigmóide para classificação binária. O modelo alcançou acurácia de 90,54%, superando resultados apresentados no artigo de referência (89,74%). Os testes demonstram boa capacidade de generalização, embora erros específicos estejam relacionados ao desbalanceamento do dataset. Os resultados reforçam a relevância de CNNs para tarefas de visão computacional e indicam possíveis melhorias futuras.*

1.INTRODUÇÃO

A classificação automática de imagens é um dos principais desafios da área de Visão Computacional, tendo sido amplamente impulsionada pelo desenvolvimento de Redes Neurais Convolucionais (CNNs). Entre os problemas clássicos está a distinção entre gatos e cães, que envolve variações de textura, postura, iluminação e cenário.

Este trabalho utiliza o dataset **Cat_and_Dog.csv** do Kaggle para explorar a aplicação de uma CNN na classificação binária entre as classes “gato” (0) e “cão” (1). As imagens foram redimensionadas para 128×128 pixels e organizadas em batches de 32 amostras para treinamento. O objetivo geral foi avaliar o desempenho da rede e compará-la com um modelo previamente publicado, utilizado como base metodológica.

Nesta introdução foram contemplados os itens solicitados: contextualização, descrição do que foi feito, como foi feito, por que foi feito e apresentação do restante do artigo. As seções seguintes detalham a metodologia, os experimentos, os resultados obtidos e a discussão final.

2. METODOLOGIA

2.1 Dataset

O dataset Cat_and_Dog.csv contém milhares de imagens anotadas como pertencentes às classes “cat” ou “dog”. Foi adotado apenas o conjunto disponibilizado, sem adição de bases externas. Observou-se um **leve desbalanceamento**, com mais imagens de cães do que de gatos.

2.2 Pré-processamento

As imagens foram redimensionadas para **128×128 pixels**, normalizadas entre 0 e 1 e divididas em conjuntos de treinamento e teste. O batch size selecionado foi de **32**, conforme experimentos iniciais que indicaram bom custo-benefício entre desempenho e tempo de treinamento.

2.3 Arquitetura da Rede Neural

A arquitetura segue o padrão tradicional de CNNs, composta por:

- camadas convolucionais com filtros 3×3,
- camadas de pooling para redução da dimensionalidade,
- camadas densas finais,
- ativação sigmóide para saída binária.

O otimizador utilizado foi **Adam**, por sua estabilidade e ampla utilização no estado da arte.

2.4 Protocolo Experimental

O treinamento foi conduzido por múltiplas épocas (um número “n” de épocas definidas pelo autor), utilizando validação cruzada para monitoramento. O desempenho foi mensurado em acurácia, “loss” (perda) e testes visuais com imagens fora do dataset.




Figura 1. Uma das imagens testadas com a cadela de um dos integrantes.




Figura 2. Uma das imagens testadas com o cachorro de um dos integrantes.



Figura 3. Uma das imagens testadas com a cadela de um dos integrantes.



Figura 4. Uma das imagens testadas com a gata de uma colega.



Figura 5. Uma das imagens testadas com a gata de uma colega de classe.



Figura 6. Uma das imagens testadas com o cachorro de um dos integrantes.

3. RESULTADOS

O modelo alcançou **90,54% de acurácia**, superando o valor de **89,74%** relatado no artigo de referência.

As Figuras 1 a 4 e 6 apresentam exemplos corretamente classificados, com **confiança superior a 80%**. A Figura 5 mostra um caso de falha de classificação.

4. DISCUSSÃO

Os resultados indicam que o modelo possui boa capacidade de generalização e é capaz de superar a implementação base utilizada como referência. A falha apresentada na Figura 5 pode ser atribuída a fatores como:

- **desbalanceamento** entre imagens de cães e gatos,
- presença de ruídos ou baixa qualidade na imagem,
- características visuais ambíguas.

Essa análise reforça a necessidade de técnicas de compensação, como *data augmentation* e reequilíbrio das classes.

5. CONCLUSÃO

Este trabalho demonstrou a capacidade de uma CNN simples em classificar imagens de gatos e cães com desempenho competitivo. O modelo superou a acurácia do artigo-base e apresentou bons resultados qualitativos. Trabalhos futuros podem incluir:

- balanceamento mais rigoroso do dataset,
- uso de arquiteturas mais profundas,
- aplicação de *transfer learning*.

Os resultados obtidos demonstram a eficiência e aplicabilidade de CNNs para problemas reais de classificação de imagens.

6. Referências

Dyer, Nhật Thăng Huỳnh. (2025). “classification-cat-dog”. Kaggle. Disponível em: <https://www.kaggle.com/code/nhtthnghunh/classification-cat-dog>. Acesso em: 08 dez. 2025.